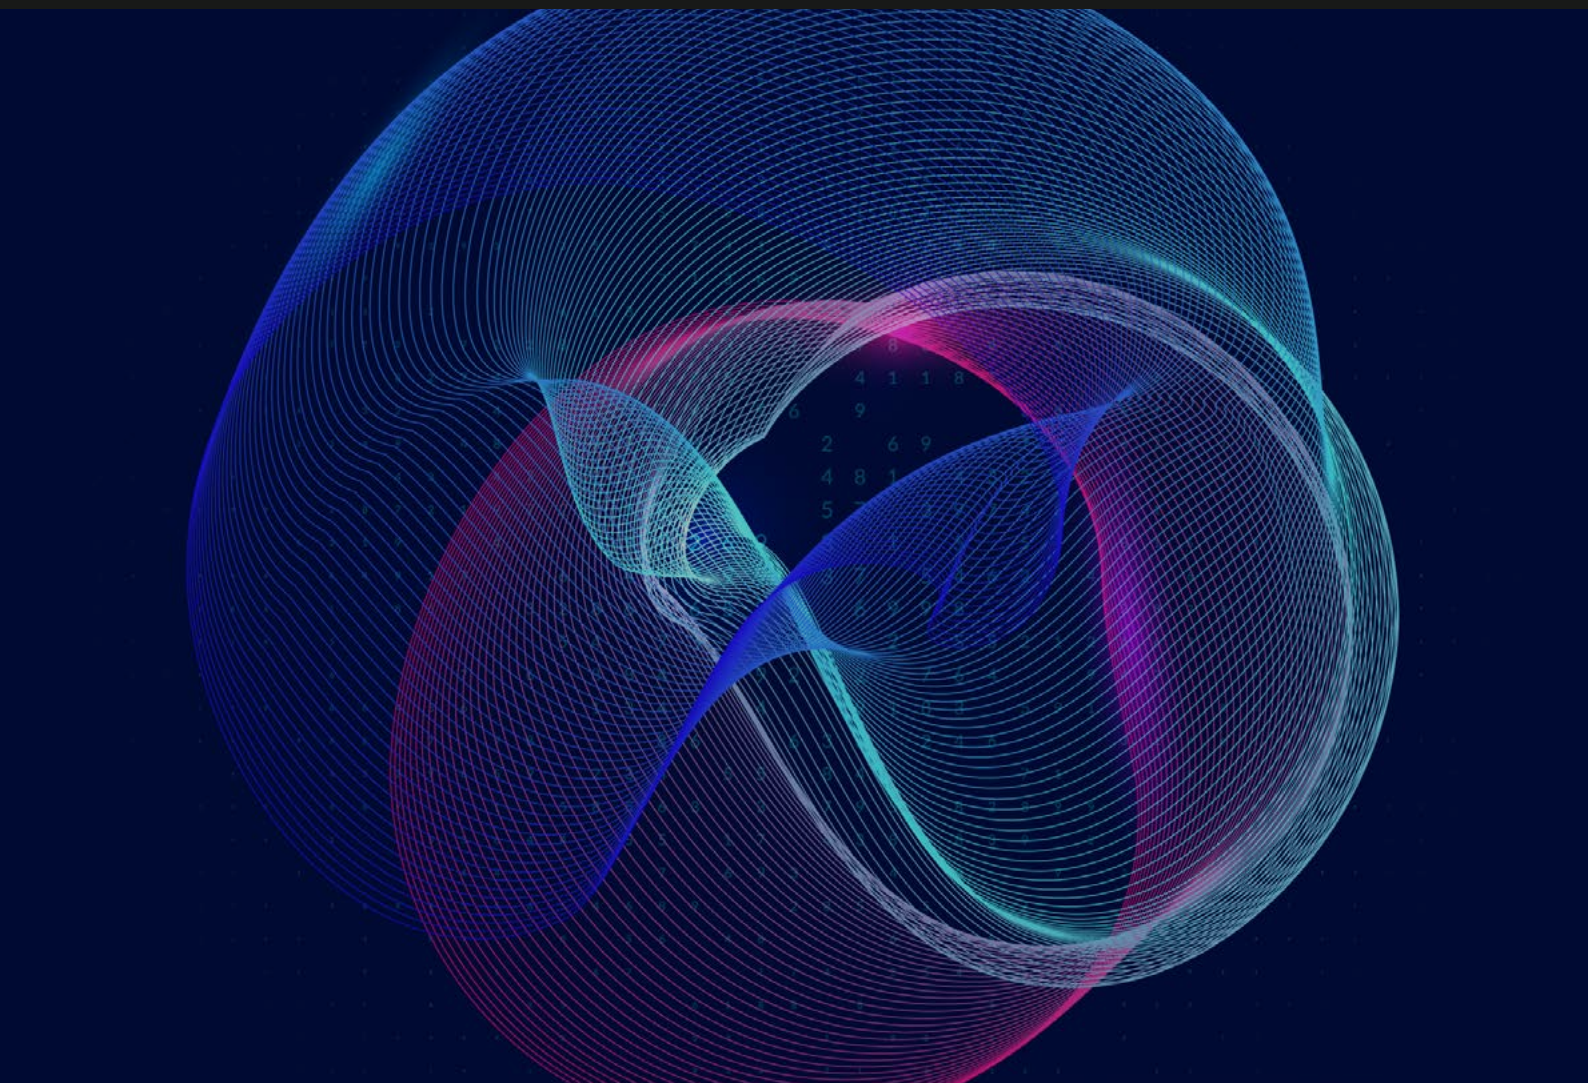
MIT | xPRO

THE MIT WAY

Utiliza los datos para tomar mejores decisiones de negocios. Sácale el máximo partido a Big Data con un curso online de 8 semanas de MIT.

DATA SCIENCE Y BIG DATA: DECISIONES BASADAS EN DATOS



THE MIT WAY

¿Podrías utilizar tus datos de manera más efectiva?

En los últimos años se han generado el 90 % de los datos que manejamos. Frente a esta abrumadora cantidad de datos, las empresas luchan por extraer los conocimientos que necesitan para tomar decisiones de negocios más inteligentes. Con el propósito de ayudar a revelar el verdadero valor de los datos, el Institute for Data, Systems, and Society (IDSS) de MIT ha creado el curso online Data Science y Big Data: Decisiones basadas en Datos para profesionales de la ciencia de datos que buscan aprovechar los datos de manera innovadora.

Durante 8 semanas, llevarás tu capacidad para el análisis de datos al siguiente nivel a medida que aprendes la teoría y la práctica subyacente a los sistemas de recomendación, las regresiones, los modelos de red y gráficos, la detección de anomalías, las pruebas de hipótesis, el machine learning y el análisis de big data.

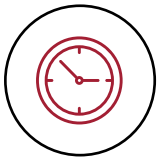
A QUIÉN VA DIRIGIDO

Profesionales en cualquier etapa de su carrera que buscan convertir grandes conjuntos de datos en información que se pueda procesar.

Entre los antiguos estudiantes ha habido: analistas de inteligencia empresarial, consultores de gestión, mánager técnicos, mánager de negocios, mánager de ciencia de datos.

Fanáticos de la ciencia de datos y profesionales de TI.

Copyright © Massachusetts Institute of Technology 2022



Duración

8 semanas



Tiempo de dedicación

5-7 horas por semana



Formato

Online



CEU

1,8

DESPUÉS DE ESTE CURSO PODRÁS:

- √ Aplicar técnicas de ciencia de datos para enfrentar el reto que supone la gestión de datos en la empresa.
- √ Determinar la diferencia entre modelos gráficos y modelos de red.
- √ Convertir conjuntos de datos en modelos mediante el análisis predictivo.
- √ Implementar algoritmos de machine learning para mejorar a la hora de tomar decisiones de negocios.
- √ Dominar las mejores prácticas para el diseño de experimentos y las pruebas de hipótesis.
- √ Identificar y evitar los errores comunes en el análisis de Big Data.

Copyright © Massachusetts Institute of Technology 2022

CALENDARIO DEL CURSO

SEMANA 1

Módulo 1: Dar sentido a datos no estructurados

FACULTY LEADS:
Stefanie Jegelka y Tamara Broderick

Los participantes aprenderán:

1. La diferencia entre el aprendizaje supervisado y el aprendizaje no supervisado.

2. Cómo aplicar técnicas de clasificación y clusterización.

3. Cómo funciona el algoritmo K-medias y cómo implementarlo.

4. Qué son los modelos de pertenencia mixta y la asignación de atributos.

5. Qué es el análisis de componentes principales (ACP) y cómo calcularlo a través de los vectores propios.

6. Qué es el agrupamiento espectral y la modularidad, así como el término "encajes".

Cuestionario inicial obligatorio no evaluable
(Completa este cuestionario para ver el contenido del curso).

Introducción

Agrupamiento (Tamara Broderick)

Estudios de caso:

- Estudio de caso 1: Códigos genéticos
- Estudio de caso 2: Encontrar temas en la descripción del proyecto

Actividades evaluables:

Completar la actividad del módulo 1.1
(Fecha de entrega: al final del curso)

Agrupamiento espectral, componentes e inserciones (Stefanie Jegelka)

Estudios de caso:

- Estudio de caso 3: ACP: Identificación de caras
- Estudio de caso 4: Agrupamiento espectral: agrupación de noticias

Actividades evaluables:

Completar la actividad del módulo 1.2
(Fecha de entrega: al final del curso)

Copyright © Massachusetts Institute of Technology 2022

SEMANA 2 y 3

Módulo 2: Regresión y predicción

FACULTY LEADS:
Victor Chernuzkov

Los participantes serán capaces de:

1. Reconocer un problema de regresión.
2. Proponer un modelo adecuado con un propósito de inferencia.
3. Diferenciar la correlación y la causalidad.
4. Identificar contextos de altas dimensiones.
5. Seleccionar el método apropiado para un contexto de altas dimensiones.
6. Comprender las limitaciones de los estudios observacionales para la inferencia causal, poniendo un especial énfasis en el factor de confusión.
7. Distinguir e implementar estudios controlados aleatorizados y realizar inferencias causales en ellos.

Regresiones y extensiones lineales y no lineales clásicas

Estudios de caso:
- Estudio de caso 1: Predecir salarios 1
- Estudio de caso 2: Brecha salarial de género

Regresión moderna con datos de alta dimensión

Estudio de caso:
- Estudio de caso 3: ¿Crecen los países pobres más rápido que los países ricos?

El uso de la regresión moderna para la inferencia causal

Pruebas controladas aleatorizadas

Estudios observacionales con factores de confusión

Estudios de caso:
- Estudio de caso 4: Predecir salarios 2
- Estudio de caso 5: El efecto de la posesión de armas en las tasas de homicidio

Actividades evaluables:
Completar la actividad del módulo 2
(Fecha de entrega: al final del curso)

SEMANA 4

Módulo 3.1
Clasificación y verificación de hipótesis

FACULTY LEADS:
David Gamarnik &
Jonathan Kelner

Los participantes serán capaces de:

1. Asimilar los principios de la detección de anomalías.
2. Formular un problema de comprobación de hipótesis.
3. Entender el concepto de valor p.
4. Describir varios algoritmos de machine learning para la clasificación.

Clasificación y verificación de hipótesis

Estudio de caso:
Caso de estudio 1: Regresión logística: Accidente del Challenger

Actividades evaluables:
Completar la actividad del módulo 3.1 (Fecha de entrega: al final del curso)

Copyright © Massachusetts Institute of Technology 2022

SEMANA 5

Módulo 3.2 Deep learning

FACULTY LEADS:
Víctor Chernuzkov

Los participantes serán capaces de:

1. Comprender el concepto de deep learning.
2. Describir la retropropagación.

Estudio de caso:
Estudio de caso 2: Límite de decisión de una red neuronal profunda

Actividades evaluables:
Completar la actividad del módulo 3.2 (Fecha de entrega: al final del curso)

SEMANA 6

Módulo 4 Sistemas de recomendación

FACULTY LEADS:
Devavrat Shah y
Phillipe Rigollet

Los participantes serán capaces de:

1. Diferenciar entre la predicción tradicional y los sistemas de recomendación.
2. Distinguir entre recomendaciones basadas en usuario y recomendaciones basadas en ítems.
3. Describir las configuraciones bajo las cuales la descomposición en valores singulares, DVS (Singular Value Decomposition, SVD), funciona correctamente.
4. Identificar sistemas de recomendación con diferentes tipos de datos.
5. Hacer uso del active learning (aprendizaje activo) para compilar datos de manera eficiente.
6. Ser consciente de la variedad de principios en los que se sostienen los sistemas de recomendación.

Recomendaciones y ranking

Filtrado colaborativo

Estudios de caso:
- Estudio de caso 1: Recomendar películas (Evaluable)
- Estudio de caso 2: Recomendar canciones nuevas a usuarios en función de lo que suelen escuchar
- Estudio de caso 3: Hacer recomendaciones de nuevos productos

Conclusión:
- Pautas sobre el sistema de construcción
- Observaciones y desafíos finales

Actividades evaluables:
- Completar la actividad del módulo 4 (Fecha de entrega: al final del curso)
- Estudio de caso evaluable: Resolución y envío
- Estudio de caso evaluable: Revisión y envío del trabajo de tres compañeros
- Resolución y envío de tu estudio de caso (Fecha de entrega: el domingo por la noche al final de la semana)
- Revisión y envío del trabajo de tu compañero (Fecha de entrega: la noche siguiente)

Copyright © Massachusetts Institute of Technology 2022

SEMANA 7

Módulo 5: Networking y modelos en grafo

FACULTY LEADS:
Caroline Uhler y Guy Bresler

Los participantes serán capaces de:

1. Cuándo están tratando con datos de red o cuándo una red es la mejor vía para representar unos datos.
2. Varios modelos de redes y sus dinámicas.
3. Varios algoritmos presentes en las redes.
4. Los fundamentos de los modelos de grafo.
5. Las limitaciones del aprendizaje de los efectos causales de los datos observacionales

Introducción

Redes

Modelos en grafo

Estudios de caso:
- Estudio de caso 1: Navegación/GPS
- 1.1 Filtro de Kalman: Seguimiento de la posición 2D de un objeto cuando se mueve a velocidad constante
- 1.2 Filtro de Kalman: Seguimiento de la posición 3D de un objeto que cae debido a la gravedad
- Estudio de caso 2: Identificar nuevos genes que causan autismo

Actividades evaluables:
Completar la actividad del módulo 5
(Fecha de entrega: al final del curso)

SEMANA 8

Módulo 6: Análisis predictivo

FACULTY LEADS:
Kalyan Veeramachaneni

Los participantes serán capaces de:

1. Reconocer cuándo trabajan con datos temporales, en contraposición a aquellos que no dependen del tiempo.
2. Definir correctamente ejemplos de entrenamiento y variables de salida.
3. Conocer varios algoritmos para el aprendizaje de atributos (feature learning).
4. Conocer las bases de la selección de modelos y sus diversas técnicas.

Modelado predictivo para datos temporales

Ingeniería de factores

Estudios de caso:
- Estudio de caso 1: NYC Taxi (Evaluable)
- Estudio de caso 2: Conjunto de datos de minoristas del Reino Unido

Actividades evaluables:
Completar TODAS las actividades (Fecha de entrega: al final del curso)

Estudio de caso evaluable:
- Resolución y envío de tu estudio de caso
  (Fecha de entrega: el domingo por la noche al final de la semana)
- Revisión y envío del trabajo de tu compañero
  (Fecha de entrega: la noche siguiente)

Actividades obligatorias:
Completar el cuestionario final
(Fecha de entrega: último día del curso)

Certificado del curso:
Obtener el certificado del curso de MIT y 1,8 MIT CEU (Descárguelo desde su interfaz. Se emitirá el día posterior a la finalización del curso)

Acceso al curso:
Acceso durante 3 meses después de la finalización del curso