


DataOps para el Data Engineer y el Data Scientist




Desarrollo de modelos tradicionales vs ML


Programación tradicional




Machine Learning



Modelado tradicional



DataOps en Ciencia de Datos y Machine Learning




Reducción de la deuda técnica usando DataOps


¿Cómo introducir el proceso de construcción de un modelo de ML en los pipelines y reducir el débito técnico?

- Introducción para pruebas lógicas de código y datos.
- Uso de un sistema de control de versiones
- Estrategia de ramificación y fusión
- Uso de multiples ambientes
- Reuso y contenerización
- Parametrización del proceso
- Doble orquestación.


Agile en solo en el desarrollo no hace al equipo ágil



Arquitectura de datos canonica





Arquitectura de datos para DataOps



Uso de Design Thinking en Data Analytics con DevOps

Metodología para abordar problemas mal definidos o complicados que desafían aproximaciones convencionales




- Falta de trabajo en equipo
- Falta de colaboración entre grupos
- Espera para que IT configure recursos del sistema
- Espera para acceder a datos
- Desarrollo lento
- Espera de aprobaciones
- Arquitecturas de datos inflexibles
- Cuellos de botella en procesos
- Débito técnico
- Baja Calidad

- Manejo de proyectos usando Agile
- Creación de ambientes de producción y desarrollo alineados
- Orquestación del aseguramiento de la calidad y del despliegue continuo del código
- Orquestación automática del pipeline de valor
- Pruebas de validación de la data y la lógica de negocio

Agile Data Warehousing


Aplicación de principios ágiles a proyectos de data warehouse para mejorar la velocidad de innovación —> No implica que el equipo sea ágil



- Dificultades para:**
- Compartir datos entre máquinas y ambientes.
 - Aprovisionamiento de máquinas físicas diferentes.
 - Gestión y mantenimiento manual de ambientes en máquinas físicas diferentes
 - Realizar pruebas y capturar errores
 - Eliminar riesgos en el despliegue de código.
 - Gestionar los equipos humanos que realizan las labores anteriores

Aceleración de la Innovación con DataOps

El almacenamiento de datos en bruto y procesados (CMR, ERP, ...) es fundamental para garantizar un acceso fácil y responder rápidamente.



- En el data lake solo se colocan datos que serán consumidos por usuarios
- Colocar todos los campos entregados por la fuente.
- Limpie, cure y transforme solo los datos requeridos
- La estructura del data lake debe ser acorde al data warehouse.
- Tenga un gobierno de datos estricto.
- Genere data marts con datasets que requieran los consumidores de datos y faciliten su labor.
- Mantenga backups del data lake

Esquemas en bases de datos


Esquemas

- Definición de las tablas.
- Tipos de datos bien definidos.
- Relaciones (uno a uno, uno a muchos, muchos a muchos).
- Campos clave.
- Reglas de negocio.
- Optimizado para inserciones y actualizaciones

En DA debe ser optimizado para lecturas, agregaciones y entendimiento de las personas


Qué pasa cuando se desea agregar un nuevo campo para análisis?

- Se agrega el nuevo campo a una tabla.
- Se agrega una nueva tabla que una el campo nuevo con uno existente.



Reuso de código en Data Analytics



Value Pipeline




- La separación en pequeños componentes permite la reutilización de código.
- Cada componente puede tener una lógica compleja y estar escrito en un lenguaje diferente y requerir un stack de software distinto.
- Es difícil llevar un componente de una máquina o ambiente a otro

- Contenerización del ambiente de desarrollo
- Contenerización de las aplicaciones

Docker es un proyecto de código abierto para el despliegue de aplicaciones dentro de contenedores para la virtualización de aplicaciones



Fallas en DA y altas expectativas

- Los dashboards son tan valiosos como la data detrás de ellos, la cual usualmente es de baja calidad.
 - Los datasets son peculiares y difíciles de manipular.
 - Los usuarios tienen conocimiento de negocio pero saben poco sobre que pueden hacer los datos por ellos.
 - Es imposible realizar grandes proyectos que reconstruyan la tubería de datos.
 - Los equipos de DA no tienen acceso a la data.
 - Se sabe que la integración de datos de bases de datos dispersas es dura, pero es mucho mas dura de lo que la gente piensa
- 
- Use métodos ágiles para crear nuevas analíticas.
 - La infraestructura debe permitir que los equipos trabajen juntos usando agile.
 - Inicie con proyectos pequeños y simples.
 - Cree rapidamente algo que de valor.
 - Obtenga retroalimentación de los usuarios.
 - Repita iterativamente.
- Implemente procesos automáticos de monitoreo de datos.
- Automatice los flujos de trabajo y el despliegue de nuevas analíticas.
 - Orqueste el proceso completo.
 - Un ingeniero de datos debe soportar 10 analistas y científicos de datos, que finalmente soportan 100 profesionales del negocio

DataOps para el Data Engineer y el Data Scientist

