


Origen y Evolución de Business Analytics

¿Por qué las organizaciones necesitan analítica?



La analítica transforma **datos** en **conocimiento** para apoyar mejores **decisiones**.

Caso de estudio: House of Cards (Netflix, 2013)

¿Cómo decidir si invertir más de USD 100 millones en una serie sin producir primero un episodio piloto?

Primera
decisión

¿Cómo decidir si invertir más de USD 100 millones en una serie sin producir primero un episodio piloto?

Analizó el comportamiento de millones de usuarios y encontró una combinación muy atractiva:

- Un gran número de suscriptores veía películas protagonizadas por **Kevin Spacey**.
-
- Existía una gran audiencia para las películas dirigidas por **David Fincher**.
- La versión británica de **House of Cards** gozaba de gran aceptación entre sus usuarios.
-
- Los dramas políticos mostraban un alto nivel de consumo y de fidelidad.

La conclusión fue que la intersección de esas audiencias era lo suficientemente amplia como para justificar la inversión.

Segunda
decisión

¿Cómo debía publicarse la temporada?

Netflix ya sabía que:

- Por los patrones de visualización de sus usuarios, que muchas personas preferían ver varios episodios consecutivos en lugar de esperar una semana entre capítulos.
- Desde la época del alquiler de DVD observaba que los usuarios consumían temporadas completas cuando tenían esa posibilidad.

Por ello decidió publicar los 13 episodios el mismo día, dando origen al modelo moderno de binge watching (maratones de series).



Caso de estudio: House of Cards (Netflix, 2013)

Business Analytics no elimina la incertidumbre.

La convierte en una decisión informada.



Netflix no podía saber qué iba a ocurrir. Lo que podía hacer era tomar una decisión aprovechando mejor la información disponible.

**Pero para tomar decisiones con datos...
primero necesitamos datos.**

1970 — Relational Database Management System

¿Cómo puede una organización almacenar digitalmente la información que anteriormente se administraba en papel?

RDBMS: sistema de gestión de bases de datos relacionales que facilita la búsqueda y la organización de grandes volúmenes de datos estructurados.

Componentes


- Esquemas → **Esquemas**
- Tablas
- Consultas
- Reportes
- Vistas
- Otros elementos
- Definición de las tablas.
- Tipos de datos bien definidos.
- Relaciones (uno a uno, uno a muchos, muchos a muchos).
- Campos clave.
- Reglas de negocio.

Funciones

- Definición.
- Manipulación (inserción, borrado, actualización, ...)
- Seguridad e integridad.
- Recuperación y restauración.

Idea clave:

La información deja de administrarse manualmente y pasa a almacenarse en tablas relacionadas.



Principales RDBMS modernos

- Oracle
- PostgreSQL
- Microsoft SQL server
- MySQL
- SQLite
- ...

1976 — Structured Query Language (SQL)

¿Cómo pueden automatizarse las operaciones que anteriormente se realizaban manualmente sobre una base de datos?

Idea clave:

SQL convierte las operaciones manuales sobre una base de datos en procesos programables y reutilizables.

SQL: lenguaje de consulta desarrollado originalmente por **IBM** para consultar y manipular bases de datos relacionales, y posteriormente incorporado por **Oracle** en el primer sistema comercial de gestión de bases de datos relacionales (RDBMS).

Data Definition Language (DDL)

- Create
- Alter
- Truncate
- Rename
- Drop

Data Manipulation Language (DML)

- Insert
- Update
- Delete
- Select

Data Control Language (DCL)

- Grant
- Revoke

Transactions Control Language (TCL)

- Commit
- Rollback
- Savepoint

```
CREATE TABLE 'CUSTOMERS';

ALTER TABLE 'ALUMNOS' ADD EDAD INT UNSIGNED;

DROP TABLE 'ALUMNOS';

TRUNCATE TABLE 'NOMBRE_TABLA';

SELECT * FROM vehículos ORDER BY marca, modelo;

SELECT DISTINCT marca, modelo FROM vehículos;

INSERT INTO agenda_telefonica (nombre, numero)
VALUES ('Roberto Pepe', 4886850);

INSERT INTO phone_book2 ( [name], [phoneNumber] )
SELECT [name], [phoneNumber]
FROM phone_book
WHERE name IN ('John Doe', 'Peter Doe')

DELETE FROM tabla WHERE column1 = 'valor1';
```


1980s — Sistemas de Información Empresariales

¿Cómo pueden las organizaciones automatizar sus procesos de negocio mediante aplicaciones especializadas?

Sistemas funcionales: Las bases de datos relacionales impulsaron el desarrollo de aplicaciones funcionales para automatizar las distintas áreas de la organización:

- Contabilidad
- Nómina
- Tesorería
- Inventarios
- Compras
- Ventas
- Producción

Sistemas integrados: aplicaciones empresariales desarrolladas sobre bases de datos relacionales que integran procesos de negocio de diferentes áreas funcionales (por ejemplo, contabilidad, ventas, inventarios y recursos humanos) mediante una base de datos común.



Idea clave:

Los sistemas de información evolucionaron hacia soluciones empresariales integradas, lo que generó la necesidad de integrar también su información.

ERP (Enterprise Resource Planning): sistema integrado para administrar y automatizar los principales procesos internos de la organización, como contabilidad, compras, inventarios, producción, ventas y nómina.

CRM (Customer Relationship Management): sistema para gestionar la información de clientes, ventas, mercadeo y servicio al cliente a lo largo de todo el ciclo de la relación comercial.

SCM (Supply Chain Management): sistema para planificar y gestionar la cadena de suministro, incluyendo compras, inventarios, logística, distribución y la relación con los proveedores.


HCM (Human Capital Management): sistema para administrar el talento humano, que incluye selección, contratación, capacitación, evaluación del desempeño y desarrollo profesional.

Además de estos sistemas, las organizaciones utilizan aplicaciones especializadas como WMS, TMS, MES, PLM y EAM, todas ellas soportadas por bases de datos relacionales y potenciales fuentes de información para un Data Warehouse.

1984 — Classification and Regression Trees (CART)

¿Cómo pueden construirse reglas de decisión automáticamente a partir de los datos para clasificar casos o predecir valores?

Classification and Regression Trees (CART): metodología de aprendizaje supervisado introducida por Breiman, Friedman, Olshen y Stone para construir árboles de decisión mediante particiones sucesivas de los datos, aplicable tanto a problemas de clasificación como a problemas de regresión. La monografía original de 1984 formalizó precisamente el uso de reglas con estructura de árbol para el análisis de datos.



Idea clave:

Los árboles transforman relaciones complejas entre variables en una secuencia interpretable de reglas de decisión, aprendidas directamente a partir de los datos.

```
if x2 > C then
    class = azul
else
    if x1 < A then
        class = verde
    else
        if x2 < B then
            class = rojo
        else
            class = amarillo
        end if
    end if
end if
```

Las empresas ya tenían datos.

El problema era recordar.

1985 — Data Warehouse

¿Cómo puede conservarse la información histórica si las bases de datos operacionales sobrescriben continuamente los datos?

Idea clave:

El Data Warehouse preserva la memoria histórica de la organización para apoyar el análisis y la toma de decisiones.


Data Warehouse: Repositorio corporativo orientado al análisis, diseñado para integrar y conservar información histórica proveniente de las diferentes bases de datos de la organización (por ejemplo, ventas, nómina, inventarios y contabilidad), proporcionando una visión integrada para la consulta y el análisis.

Arquitectura:

- Orientado a temas
- Integrado
- Orientado al análisis y consulta

Información:

- No volátil
- Variable en el tiempo
- Histórico.




1985 — ETL

¿Cómo puede mantenerse actualizado un Data Warehouse alimentado por múltiples sistemas de información?

Idea clave:

Los procesos ETL integran, transforman y consolidan la información corporativa.

ETL (Extract, Transform, Load): Proceso de **EXTRACCIÓN** (obtención de información de diferentes sistemas de la organización), **TRANSFORMACIÓN** (preparación de la información para facilitar su análisis, corrigiendo errores, eliminando duplicados y unificando formatos) y **CARGA** (almacenamiento de la información procesada en el Data Warehouse para su consulta y análisis).



Características

- Automatiza la actualización periódica del Data Warehouse.
- Corrige errores, elimina registros duplicados y unifica los formatos de la información.
- Integra información proveniente de múltiples bases de datos de la organización.
- Puede ejecutarse por lotes (batch) o en tiempo real (stream).
- Puede iniciarse manualmente, mediante programación o mediante eventos de monitoreo.

¿Quién es realmente tu mejor cliente?


¿Qué podemos descubrir de un cliente al analizar toda su historia y no solo una transacción?

Idea clave:

Una transacción representa una operación. La historia revela el comportamiento.


Una transacción

¿Cuánto gastó hoy?
¿Qué hizo en esta visita?



Su historia

¿Con qué frecuencia viene?
¿Qué actividades prefiere?
¿Cómo responde a las promociones?
¿Cuánto valor genera a lo largo del tiempo?



Los mejores clientes no eran necesariamente los grandes apostadores.

1989 — Business Intelligence 1.0 (1989)

¿Cómo pueden responderse nuevas preguntas de negocio cuya información no está disponible en los EIS ni en los sistemas operacionales?


Business Intelligence 1.0: Conjunto de herramientas, productos y tecnologías para **consultar**, **visualizar** y **analizar** la **información disponible** en una organización, que apoya la generación de reportes, indicadores y tableros para la toma de decisiones.

Entre sus tareas típicas se encuentran:

- Visualización de información.
- Cálculo de indicadores (KPIs).
- Dashboards ejecutivos.
- Reportes automáticos.
- Consultas ad hoc.

Idea clave:

Los ejecutivos solicitan al área de TI la construcción de nuevos reportes, indicadores y tableros a partir de la información almacenada en el DW




¿Cómo pueden descubrirse automáticamente patrones ocultos en grandes bases de datos?


Data Mining: Proceso computacional para descubrir patrones, tendencias y relaciones útiles en grandes conjuntos de datos mediante la aplicación de métodos estadísticos a la información almacenada en bases de datos. Entre sus tareas típicas se encuentran:

- Descubrimiento de reglas de asociación.
- Clasificación.
- Regresión.
- Agrupamiento (clustering).
- Detección de anomalías.

- RDBMS**
- Sistemas funcionales
 - Sistemas integrados



Nueva pregunta de negocio



El analista reemplaza la consulta por la construcción de un modelo que descubre conocimiento oculto en los datos.

Idea clave:

Los modelos estadísticos comienzan a utilizarse para descubrir conocimiento almacenado en bases de datos.


- Un modelo de clasificación
- Un modelo de regresión
- Reglas de asociación
- Segmentaciones
- Árboles de decisión
- Un informe técnico con hallazgos

¿Cómo puede estructurarse un proceso sistemático para descubrir conocimiento a partir de los datos?

Idea clave:

KDD formaliza las etapas necesarias para descubrir conocimiento útil a partir de grandes volúmenes de datos.

KDD (Knowledge Discovery in Databases): proceso iterativo para descubrir conocimiento útil en bases de datos, que comprende la selección, preparación, transformación, minería e interpretación de los datos.



El despliegue puede ser:

- un modelo implementado;
- un sistema de soporte a decisiones;
- un reporte automatizado;
- un proceso de negocio modificado;
- una aplicación que utiliza el modelo;
- una campaña de mercadeo basada en el modelo.

1993 — Sistemas OLAP


¿Cómo puede organizarse y consultarse eficientemente la información almacenada en un Data Warehouse?

Idea clave:

Los sistemas OLAP permiten realizar consultas multidimensionales rápidas e interactivas sobre grandes volúmenes de información.

OLAP (Online Analytical Processing):

Tecnología para agilizar la consulta y el análisis de grandes volúmenes de información mediante estructuras multidimensionales que permiten explorar los datos desde diferentes perspectivas.



1993 — Cubo OLAP

¿Cómo puede organizarse la misma información para analizarla desde múltiples perspectivas?

Idea clave:
El cubo OLAP organiza las medidas de negocio a través de múltiples dimensiones, lo que permite analizar la misma información desde diferentes perspectivas.

Tabla bidimensional

Fecha	Producto	Ciudad	Ventas
Ene	A	Bogotá	120
Ene	A	Medellín	150
Ene	B	Bogotá	90
Ene	B	Medellín	110
Feb	A	Bogotá	130
Feb	A	Medellín	170
Feb	B	Bogotá	95
Feb	B	Medellín	125

Cubo OLAP

Las dimensiones son:

- Fecha
- Producto
- Ciudad

La medida es:

- Ventas

Producto = A		
Ciudad	Fecha	
	Ene	Feb
	Bogotá	120
Medellín	150	170

Producto = B		
Ciudad	Fecha	
	Ene	Feb
	Bogotá	90
Medellín	110	125

¿Cómo pueden construirse modelos predictivos que aprendan patrones a partir de ejemplos y generalicen a datos no observados?

Idea clave:
El aprendizaje estadístico desplaza el énfasis desde programar explícitamente las reglas hacia aprender funciones predictivas a partir de los datos.

**Statistical Machine Learning
(Aprendizaje Estadístico):**
enfoque para construir modelos que aprenden relaciones y patrones a partir de datos, utilizando principios estadísticos para realizar predicciones o clasificaciones y generalizar a observaciones no utilizadas durante el entrenamiento.

Árbol → particiones rectangulares

SVM → hiperplano de máximo margen

Boosting → combinación de clasificadores débiles


1996 — Data Marts

¿Cómo puede proporcionarse a cada área de negocio una vista especializada de la información corporativa?

Idea clave:

Los Data Marts especializan la información corporativa para las necesidades analíticas de áreas específicas del negocio.

Data Mart: subconjunto de vistas de datos de un Data Warehouse orientado a la consulta. Es implementado usando cubos OLAP



1996 — CRISP-DM (Cross-industry standard process for data mining)

¿Cómo puede incrementarse la probabilidad de éxito de los proyectos de minería de datos?

Idea clave:

CRISP-DM incorpora el entendimiento del negocio y estandariza el desarrollo de proyectos de minería de datos.

CRISP-DM: metodología estándar para planificar, desarrollar e implementar proyectos de minería de datos, transformando problemas de negocio en soluciones analíticas mediante un proceso sistemático y repetible.



1996 — Business Intelligence 2.0



¿Cómo puede evitarse que el área de TI se convierta en un cuello de botella al responder preguntas de negocio?

Inteligencia de Negocios 2.0: conjunto de herramientas y servicios para explorar, analizar y visualizar la información organizacional, que permite a los usuarios de negocio realizar consultas interactivas y apoyar la toma de decisiones tácticas y estratégicas.

Características / Capacidades:

- Consultas interactivas (OLAP).
- Reportes.
- Dashboards (cuadros de mando).
- Gráficos.
- Mapas.
- Integración de Data Warehouses, Data Marts y cubos OLAP.

Idea clave:
Las herramientas de Business Intelligence permiten a los usuarios de negocio explorar y analizar directamente la información.




¿Cómo puede extraerse conocimiento mediante el análisis de datos almacenados electrónicamente?

Idea clave:

La Ciencia de Datos integra múltiples disciplinas para extraer conocimiento a partir de datos almacenados electrónicamente.

Ciencia de datos: campo interdisciplinario que desarrolla y aplica métodos, procesos y sistemas para analizar datos almacenados electrónicamente y extraer conocimiento de ellos, ya sean estructurados, semiestructurados o no estructurados. Domina el software propietario (S-PLUS, SPSS, Minitab, Oracle, ...)





¿Por qué Data Science transformó la industria?

¿Por qué Data Science se convirtió en una de las disciplinas más demandadas del siglo XXI?

Interés a lo largo del tiempo ⓘ

Todo el mundo · 2004 - hoy




Idea clave:

La disponibilidad masiva de datos y el desarrollo de nuevas tecnologías impulsaron una rápida adopción de la ciencia de datos en la industria, el gobierno y la academia.

Interés medio ⓘ

Todo el mundo · 2004 - hoy

Google Trends para “Data Science” y “Business Analytics”



2001 — Ensemble Learning

¿Puede la combinación de varios modelos producir predicciones mejores y más robustas que un único modelo?

Idea clave:

En lugar de depender de un solo modelo, los métodos de ensamblaje combinan múltiples modelos para mejorar la capacidad predictiva y de generalización.

Ensemble Learning (Aprendizaje por conjuntos): enfoque de aprendizaje automático que combina las predicciones de múltiples modelos para obtener un modelo conjunto con mayor precisión, estabilidad o capacidad de generalización que sus componentes individuales.

Random Forest: muchos árboles entrenados sobre muestras/variables diferentes → votación o promedio.

Gradient Boosting: árboles contruidos secuencialmente, donde cada nuevo modelo intenta corregir los errores de los anteriores → suma de modelos.

Datos → Modelo 1 + Modelo 2 + Modelo 3 + ... → combinación → Predicción final


2002 — Cloud computing

¿Cómo puede accederse de forma flexible y bajo demanda a infraestructura computacional sin adquirir infraestructura propia?


Idea clave:

La computación en la nube transforma la infraestructura computacional en un servicio escalable y bajo demanda, impulsando el desarrollo de aplicaciones analíticas y Big Data.

Computación local (Servers on premises) Servidores + red + clientes




Cloud computing / Utility computing (Servers on the cloud)



- Espacio físico.
- Costos de compra y obsolescencia
- Costos de mantenimiento y energía.
- Atención en picos de carga y subutilización la mayor parte del tiempo
- Gestión de riesgos.

- No requiere espacio físico.
- Rentados
- Escalable bajo demanda.
- Gestión de riesgos manejados por el proveedor.



Modelo	¿Qué ofrece?	Ejemplos	¿Por qué es importante en analítica?
IaaS Infrastructure as a Service	Servidores virtuales, almacenamiento, redes y capacidad de procesamiento.	AWS EC2, Azure Virtual Machines, Google Compute Engine	Permite ejecutar Hadoop, Spark, bases de datos y clústeres sin comprar servidores,
PaaS Platform as a Service	Plataformas administradas para desarrollar y desplegar aplicaciones.	Azure App Service, Google App Engine, Heroku	Facilita crear aplicaciones analíticas sin administrar la infraestructura.
SaaS Software as a Service	Aplicaciones completas accesibles mediante navegador o cliente.	Power BI, Tableau Cloud, Microsoft 365, Salesforce	El usuario consume herramientas analíticas sin instalar ni mantener software.
FaaS Function as a Service	Ejecución de funciones bajo demanda (serverless).	AWS Lambda, Azure Functions, Google Cloud Functions	Automatiza procesos de datos, APIs y flujos de IA pagando únicamente por ejecución.


Idea clave:
Los servicios en la nube ofrecen distintos niveles de abstracción, desde la infraestructura hasta las aplicaciones completas.

- Tendencias actuales:**
- Low-code/No-code: desarrollo con poca o ninguna programación.
 - Vibe Coding: desarrollo asistido por modelos de IA generativa.
 - Serverless Computing: las aplicaciones se ejecutan sin necesidad de administrar servidores.
 - AI as a Service (AlaaS): consumo de modelos de IA como servicio (OpenAI, Gemini, Claude, Azure AI).

¿Cómo pueden procesarse grandes volúmenes de información distribuida entre cientos de computadores?

Idea clave:
Big Data combina almacenamiento y procesamiento distribuidos.

Aproximación Tradicional (RDBMS y data warehouse)




- Alto volumen de datos
- Lectura lenta
- Escritura + lenta
- Búsqueda ++ lenta

RDBMS


- Orientado a filas
- Estructura fija
- SQL
- Consistencia
- Integridad referencial
- Abstracción

Procesamiento distribuido




Necesidad de poder de cómputo

Necesidad de gestión de memoria



Almacenamiento distribuido


Hadoop Distributed Filesystem (HDFS)



Nodos de Datos + Nodos de Computo

Las cinco Vs

- Volumen (Cuántos?)
- Variedad (Tipo?)
- Velocidad (Frecuencia?)
- Veracidad (Precisión?)
- Valor (Utilidad?)






Ejecución de Jobs en Hadoop

¿Cómo ejecuta Hadoop procesos complejos sobre grandes volúmenes de datos?

Idea clave:

Los problemas complejos se resuelven mediante la ejecución secuencial o en paralelo de múltiples jobs de MapReduce.

Job: Unidad de ejecución en Hadoop que aplica una o más operaciones Map y Reduce sobre datos almacenados en HDFS para producir un resultado.





¿Cuál es la principal limitación en Hadoop?

¿Qué ocurre cuando un problema requiere ejecutar múltiples Jobs de MapReduce?

Idea clave:

El almacenamiento intermedio en HDFS y el lanzamiento repetido de Jobs introducen una sobrecarga significativa en aplicaciones analíticas complejas.



¿Por qué analítica?


¿Por qué los datos se han convertido en uno de los principales activos de las organizaciones?

Idea clave:

Las organizaciones que convierten datos en decisiones obtienen ventajas competitivas sostenibles.

Antes:

- Experiencia.
- Intuición.
- Reportes.
- Decisiones periódicas.



Hoy:

- Datos.
- Modelos.
- IA.
- Decisiones en tiempo real.

Casos de éxito

¿Cómo aporta valor la analítica en las organizaciones?

Idea clave:
La analítica no pertenece a un sector; se ha convertido en una capacidad transversal de prácticamente todas las organizaciones.

Organización	Problema de negocio	Aplicación de analítica
Amazon	¿Qué productos ofrecer a cada cliente?	Recomendación personalizada de productos.
Netflix	¿Qué contenido mantener viendo al usuario?	Recomendación personalizada de películas y series.
Google	¿Qué resultados y anuncios mostrar?	Búsqueda inteligente y publicidad personalizada.
Uber	¿Cómo equilibrar oferta y demanda?	Tarifas dinámicas y asignación de conductores.
Spotify	¿Qué música recomendar?	Descubrimiento y recomendación personalizada.
Walmart	¿Qué cantidad de productos abastecer?	Pronóstico de demanda y optimización de inventarios.
JPMorgan Chase	¿Cómo reducir el fraude financiero?	Detección automática de transacciones anómalas.
Tesla	¿Cómo mejorar la seguridad de la conducción?	Análisis en tiempo real de datos de sensores.

Tener datos ya no era suficiente.

Había que convertirlos en una ventaja.

¿Cómo competir contra alguien que tiene mucho más dinero que tú?

Oakland Athletics

Uno de los presupuestos más bajos de las Grandes Ligas.

Imaginen que dirigen un equipo de béisbol.

Sus competidores pueden gastar muchísimo más que ustedes. Si todos evalúan a los jugadores de la misma manera, ustedes tienen un problema: cuando aparece un gran jugador, los equipos ricos pueden simplemente pagar más.

Billy Beane y los Oakland Athletics hicieron una pregunta diferente:

¿Y si el mercado está equivocado sobre cuánto vale un jugador?”

No necesitaban tener más dinero. Necesitaban tomar mejores decisiones.

¿Cómo pueden utilizarse los datos en las organizaciones para mejorar la toma de decisiones y generar ventajas competitivas?

Idea clave:
Business Analytics amplía la inteligencia de negocios al incorporar modelos predictivos y prescriptivos para apoyar la toma de decisiones.

Business Analytics: Campo interdisciplinario que integra datos, métodos matemáticos, estadísticos y computacionales, junto con técnicas de simulación, optimización y apoyo a la decisión, para mejorar la toma de decisiones, el desempeño y la generación de ventajas competitivas en las organizaciones.



Subscribe

Latest Magazine Topics Podcasts Store Reading Lists Data & Visuals Case Selections HBR Executive

Analytics And Data Science

Competing on Analytics

Some companies have built their very businesses on their ability to collect, analyze, and act on data. Every company can learn from what these firms do. by Thomas H. Davenport

From the Magazine (January 2006)

Competing on Analytics (Davenport, 2006) consolidó el concepto de Business Analytics al integrar una tradición proveniente de los sistemas de apoyo a la decisión (DSS), la inteligencia de negocios (BI), la investigación de operaciones (Operations Research), la minería de datos y los métodos cuantitativos, demostrando que su uso sistemático podía convertirse en una fuente sostenible de ventaja competitiva.

Analítica Descriptiva

Análisis de la situación actual para la toma de decisiones operativas

Analítica Diagnóstica

Análisis orientado a identificar las causas y factores que explican por qué se observó un resultado o comportamiento.

Analítica Predictiva

Área enfocada en el uso de técnicas de modelado predictivo, aprendizaje de máquinas y minería de datos para pronosticar los resultados de un proceso en un contexto organizacional.

Analítica Prescriptiva

Uso de técnicas de simulación, optimización y análisis de riesgo e incertidumbre para la toma de decisiones organizacionales

¿Cómo pueden desarrollarse aplicaciones para Hadoop sin programar directamente en MapReduce?

Idea clave:

Pig introduce un lenguaje de alto nivel para programar procesos distribuidos.

Apache Pig: lenguaje de alto nivel similar a SQL que permite desarrollar aplicaciones para el análisis de grandes volúmenes de datos en Hadoop mediante flujos de datos (data flows), los cuales son traducidos automáticamente a programas MapReduce.

**CROSS
EXPLAIN
FILTER
FOREACH
GENERATE
GROUP
ILLUSTRATE
JOIN
LIMIT
LOAD
ORDER
STREAM
SPLIT
STORE
SET
QUIT**

Ejemplo de Pig


```
records = LOAD 'sample.txt' AS (year:chararray, temperature:int, quality:int);
filtered_records = FILTER records BY temperature;
grouped_records = GROUP filtered_records BY year;
max_temp = FOREACH grouped_records GENERATE group, MAX(filtered_records.temperature);
DUMP max_temp;
```


¿Cómo pueden almacenarse grandes volúmenes de datos estructurados, semiestructurados y no estructurados para su análisis posterior?

Idea clave:

A diferencia del Data Warehouse, el Data Lake almacena los datos en bruto, lo que permite definir su estructura únicamente cuando se utilizan para el análisis.

Data Lake: Arquitectura de almacenamiento orientada a Big Data que proporciona un repositorio centralizado para almacenar grandes volúmenes de datos estructurados, semiestructurados y no estructurados en su formato original, permitiendo su procesamiento y análisis posteriores mediante tecnologías de Big Data y analítica avanzada.



¿Cómo pueden almacenarse grandes volúmenes de datos en estructuras flexibles que no se ajustan al modelo relacional?

Bases de datos NoSQL: sistemas de gestión de bases de datos no relacionales diseñados para almacenar grandes volúmenes de datos estructurados, semiestructurados y no estructurados mediante modelos de datos flexibles y escalables.

Pares <clave, valor>
Tabla**001**.Fecha=2017-10-01
Tabla**001**.Planta=Jaguas
Tabla**001**.Generación=100.2
Tabla**002**.Fecha=2017-10-01
Tabla**002**.Planta=Playas
Tabla**002**.Generación=23.1
Tabla**003**.Fecha=2017-10-01
Tabla**003**.Planta=Guatapé
Tabla**003**.Generación=130.1

Datos tabulares

KEY	Fecha	Planta	Generación
001	2017-10-01	Jaguas	100.2
002	2017-10-01	Playas	23.1
003	2017-10-01	Guatape	130.1

Document (JSON/XML)

```
[
  {
    Fecha:2017-10-01,
    Planta:Jaguas,
    Generación: 100.2
  },{
    Fecha:2017-10-01,
    Planta:Playas,
    Generación:23.1,
  },{
    Fecha:2017-10-01,
    Planta:Guatapé,
    Generación:130.1
  }
]
```

Sistema orientado a filas
001:2017-10-01,Jaguas,100.2
002:2017-10-01,Playas,23.1
003:2017-10-01,Guatape,130.1

Column family database
001:{Fecha:2017-10-01, Planta:Jaguas, Generación:100.2}
002:{Fecha:2017-10-01, Planta:Playas, Generación:23.1}
003:{Fecha:2017-10-01, Planta:Guatapé, Generación:130.1}

Idea clave:
Las bases de datos NoSQL amplían el paradigma relacional mediante modelos de datos flexibles diseñados para aplicaciones Big Data y sistemas distribuidos.


YAML
001:
 Fecha: 2017-10-01
 Planta: Jaguas
 Generación: 100.2
002:
 Fecha: 2017-10-01
 Planta: Playas
 generación: 23.1
003:
 Fecha: 2017-10-01
 Planta: Guatape
 Generación: 130.1

2009-2012 — Open Data Science

¿Cómo puede desarrollarse la ciencia de datos sin depender de plataformas propietarias?

Open Data Science:

movimiento basado en software de código abierto que impulsó la adopción de lenguajes como Python y R, junto con sus ecosistemas de bibliotecas, para el desarrollo de aplicaciones de ciencia de datos.




La analítica dejó de depender de unas pocas herramientas y organizaciones.

Empezó a convertirse en un ecosistema.

2010-2015 — Modern Analytics

¿Qué ocurre cuando Big Data, Machine Learning y los ecosistemas abiertos comienzan a converger?

Idea clave:
La analítica moderna emerge de la convergencia entre nuevos ecosistemas de software, Big Data, computación distribuida y Machine Learning.



2011-2012 — Producto de Datos

¿Cómo pueden los datos transformarse en aplicaciones que generen valor de forma continua?


Producto de datos: aplicación o servicio que integra datos y algoritmos para generar continuamente predicciones, recomendaciones, decisiones o información útil y que, además, produce nuevos datos que pueden ser consumidos por otros productos de datos o procesos analíticos.

Estadística y aprendizaje de máquinas

Los datos están listos



Modelado de datos





Idea clave:

Los productos de datos integran datos y algoritmos para aprender continuamente, adaptarse automáticamente y generar valor de forma escalable.

Inteligencia de Negocios



DW / OLAP



Generación, agregación, análisis y visualización de datos del negocio

Minería de Datos







DW / OLAP



Descubrimiento de patrones y tendencias claves

Analytics

DW / OLAP
Hadoop & Spark
NoSQL ...



¿Cuánto vale ahorrar unos pocos kilómetros?

13 kilómetros menos por conductor, cada día.

≈ 130 millones de millas menos al año

≈ 10 millones de galones de combustible ahorrados


Una pequeña decisión × millones de veces = un impacto enorme

Datos → algoritmo → decisión → operación → nuevos datos → nueva decisión

La analítica dejó de ser únicamente algo que alguien consultaba en una pantalla.
Empezó a formar parte de la operación.

¿Cómo pueden ejecutarse algoritmos analíticos tradicionales sobre plataformas Big Data?

Big Data Analytics (Análítica de Big Data): Disciplina que aplica métodos matemáticos, estadísticos y computacionales para descubrir conocimiento, identificar patrones y apoyar la toma de decisiones mediante el análisis de grandes volúmenes de datos estructurados, semiestructurados y no estructurados.



Apache Mahout

Implementación en Map/Reduce (Java y otros) de los algoritmos de aprendizaje estadístico y aprendizaje de máquinas

Idea clave:

Los algoritmos estadísticos y de Machine Learning comienzan a ejecutarse en arquitecturas distribuidas.

Estadística básica

Clasificación y regresión

Filtrado colaborativo

Agrupamiento

Reducción de dimensiones

Extracción de características

Minería de patrones frecuentes

Métricas de evaluación


Exportación de modelos

Optimización

¿Cómo puede automatizarse integralmente una fábrica mediante tecnologías digitales?

Idea clave:
La Analítica pasa a formar parte de la operación industrial.

Smart Factory (Fábrica Inteligente): Sistema de producción altamente digitalizado que integra sensores, sistemas ciberfísicos, Internet de las Cosas, analítica e Inteligencia Artificial para monitorear, optimizar y automatizar de forma autónoma los procesos de manufactura.



<https://www.avsystem.com/blog/smart-factory/>

2011-2012 — Auge del Deep Learning

¿Cómo pueden resolverse problemas para los cuales los modelos tradicionales resultan insuficientes?

Deep Learning (Aprendizaje Profundo): Rama del aprendizaje automático que utiliza redes neuronales artificiales con múltiples capas para aprender automáticamente representaciones jerárquicas y patrones complejos a partir de grandes volúmenes de datos, permitiendo realizar tareas de clasificación, predicción, reconocimiento y generación de información.

Red neuronal ejecutada en 1.000 computadores para etiquetar imágenes tomadas aleatoriamente de YouTube. Experimento desarrollado por investigadores de Google Brain, entre ellos Quoc Le y Andrew Ng.

¿Puede reconocer un gato sin que nadie le enseñe qué es un gato?

Idea clave:

Las redes neuronales profundas amplían el conjunto de modelos disponibles para resolver problemas analíticos.




2012 — Transformación Digital

¿Cómo puede transformarse una organización tradicional en una organización digital?

Transformación Digital: Proceso de integración de tecnologías digitales en los procesos, productos, servicios y modelos de negocio de una organización para generar valor, mejorar su desempeño y transformar la forma en que opera y compite.

Idea clave:

La transformación digital redefine cómo una organización crea valor mediante la integración de tecnologías digitales, datos, procesos, personas y nuevas formas de operar.



¿Cómo pueden consultarse grandes volúmenes de datos almacenados en Hadoop utilizando un lenguaje similar a SQL?

Apache Hive: sistema de almacenamiento y consulta de datos que proporciona un lenguaje similar a SQL (HiveQL) para consultar y analizar grandes volúmenes de datos almacenados en Hadoop mediante procesamiento distribuido.

Idea clave:
Hive democratiza el acceso a Hadoop al permitir que usuarios con conocimientos de SQL analicen grandes volúmenes de datos sin programar directamente en MapReduce.

 Apache Hive

Páginas

Blog

ACCESOS DIRECTOS DE ESPACIO

How-to articles

PÁGINAS HIJAS

LanguageManual

- LanguageManual Select
 - Common Table Expression
 - Partition Filter Syntax

[Panel](#) / [LanguageManual](#)

LanguageManual Select

Creado por Confluence Administrator, modificado por última vez por Elliot West el feb 27, 2019

- Select Syntax
 - WHERE Clause
 - ALL and DISTINCT Clauses
 - Partition Based Queries
 - HAVING Clause
 - LIMIT Clause
 - REGEX Column Specification
 - More Select Syntax

[GROUP BY](#); [SORT/ORDER/CLUSTER/DISTRIBUTE BY](#); [JOIN](#) ([Hive Joins](#), [Join Optimization](#), [Outer Join Behavior](#)); [UNION](#); [TABLESAI VIEW](#); [Windowing](#), [OVER](#), and [Analytics](#); [Common Table Expressions](#)

Select Syntax


```
[WITH CommonTableExpression (, CommonTableExpression)*] (Note: Only available starting with Hive 0.13.0)
SELECT [ALL | DISTINCT] select_expr, select_expr, ...
FROM table_reference
[WHERE where_condition]
[GROUP BY col_list]
[ORDER BY col_list]
[CLUSTER BY col_list
 | [DISTRIBUTE BY col_list] [SORT BY col_list]
]
[LIMIT [offset,] rows]
```

¿Cómo puede acelerarse el procesamiento Big Data y simplificarse su ecosistema?

Idea clave:

Spark reconstruye el ecosistema de Big Data sobre una arquitectura de procesamiento en memoria.

Apache Spark: motor de procesamiento distribuido de código abierto que permite el procesamiento y análisis de grandes volúmenes de datos mediante computación en memoria, y que soporta aplicaciones de analítica, aprendizaje automático y procesamiento de flujos de datos.



2014-2016 — Gradient Boosting a Escala

¿Cómo puede llevarse a cabo el boosting en conjuntos de datos grandes manteniendo una alta precisión y tiempos de entrenamiento prácticos?

Idea clave:

El gradient boosting se convierte en una de las familias más competitivas para datos tabulares al combinar precisión, flexibilidad y escalabilidad.

Gradient Boosting: técnica de aprendizaje supervisado que construye modelos de forma secuencial, en la que cada nuevo modelo intenta reducir los errores residuales de la combinación previa.

Modelo 1 → errores → Modelo 2 corrige → errores restantes → Modelo 3 corrige → Predicción final

Gradient Boosting → XGBoost → LightGBM → CatBoost

Data Ops (2015)





¿Cómo pueden desarrollarse productos de datos que evolucionen continuamente?

Idea clave:


Los productos analíticos pasan de ser proyectos con un final definido a convertirse en activos que evolucionan junto con el negocio.

DataOps: disciplina que integra personas, procesos y tecnologías para automatizar, gestionar y monitorear el ciclo de vida de los datos, garantizando la calidad, la confiabilidad y la entrega continua de productos de datos.


- Notebooks interactivos
- Visualización interactiva
- Modelos
- Presentaciones
- Aplicaciones web inteligentes
- Servicios RESTful
- Dashboards




Equipos de desarrollo de software & Científicos de datos



Depósito de software



Analistas de datos & Científicos de datos



2015 — DataOps: Pipelines de Innovación y Valor

¿Cómo puede innovarse continuamente sin afectar el producto que actualmente genera valor?

Idea clave:

La experimentación se separa de la operación para reducir el riesgo.

Heroísmo: Trabajo fuera de horario y fines de semana.

Escenarios desastrosos:

- Despliegue de cambios que dañan los sistemas productivos.
- Entrega de datos de poca calidad a los usuarios.


Miedo: Ausencia de confianza en que los resultados sean correctos o los cambios funcionen correctamente.

Innovation Pipeline

Value Pipeline

Value Pipeline

Innovation Pipeline




Los tests sobre los datos en cada paso garantizan la calidad de la salida

2016 — Machine Learning Operations (MLOps)

¿Cómo pueden llevarse los modelos de Machine Learning desde el laboratorio hasta ambientes de producción?

MLOps: disciplina que integra personas, procesos y tecnologías para automatizar, desplegar, monitorear y gestionar el ciclo de vida de los modelos de aprendizaje automático, garantizando su calidad, reproducibilidad, confiabilidad y operación continua en entornos de producción.



Idea clave: MLOps gestiona el ciclo de vida completo de los modelos desplegados.

Principios (ml-ops.org)

- Unificación del ciclo de machine learning y liberación de software
- Pruebas automáticas de artefactos en ML (validación de datos, pruebas de modelos, pruebas de integración).
- Soporte de modelos y datos para construir modelos como elementos principales en sistemas CD/CI
- Reducción del débito técnico
- MLOps como una práctica agnóstica (de lenguajes, plataformas e infraestructura).

Hasta aquí construíamos los modelos.


¿Qué ocurre cuando los modelos
empiezan a ayudarnos a construir la
analítica?

2017-2023 — Foundation models

¿Cómo pueden desarrollarse modelos reutilizables capaces de resolver múltiples tareas analíticas?

Idea clave:

Los modelos fundacionales proporcionan capacidades generales que posteriormente pueden adaptarse a distintos dominios.



2023-2024 — Multimodal Foundation Models


¿Cómo pueden integrarse diferentes tipos de datos en un mismo modelo para realizar tareas analíticas?

Idea clave:


Los modelos fundacionales dejan de trabajar exclusivamente con texto y comienzan a integrar múltiples modalidades de información.

Multimodal Foundation Model (Modelo Fundacional Multimodal): modelo capaz de procesar, relacionar y generar información proveniente de múltiples modalidades, como texto, imágenes, audio, video y datos estructurados.

Texto
Imágenes
Audio
Video
Datos



Multimodal
Foundation
Model




Clasificación
Predicción
Generación
Interpretación

2025-2026 — AI-augmented Analytics

¿Cómo puede la IA asistir y automatizar el trabajo del analista mediante herramientas computacionales?

Idea clave:
La IA deja de limitarse a generar respuestas y comienza a ejecutar tareas analíticas mediante código, herramientas especializadas y procesos de razonamiento asistido.



¿Cómo pueden automatizarse procesos completos mediante agentes inteligentes capaces de tomar decisiones y ejecutar acciones de forma autónoma?


Idea clave:

La IA deja de asistir al analista y comienza a ejecutar procesos completos de forma autónoma para alcanzar objetivos definidos por el usuario.

Agentic AI: paradigma de IA en el que agentes inteligentes basados en modelos fundacionales planifican, razonan, utilizan herramientas y ejecutan de forma autónoma procesos completos para alcanzar un objetivo definido por el usuario.

Capacidades de un agente inteligente:

- Comprende el objetivo planteado por el usuario.
- Planifica una estrategia para alcanzarlo.
- Utiliza herramientas como Python, SQL, APIs, navegadores, bases de datos y aplicaciones empresariales.
- Ejecuta tareas y toma decisiones intermedias.
- Evalúa los resultados y corrige errores.
- Continúa iterando hasta cumplir el objetivo.
- Presenta el resultado final al usuario.



Especialización por áreas

¿Cómo pueden adaptarse los métodos analíticos a las necesidades específicas de cada dominio de aplicación?

Domain Analytics (Análítica por Dominio): Aplicación de métodos, modelos y tecnologías analíticas para resolver problemas específicos de un área del conocimiento, una industria o una función organizacional.

- People / Human Resources Analytics
- Financial Analytics
- Accounting Analytics
- Marketing Analytics
- Inventory Analytics
- Demand Analytics
- Customer Analytics

Idea clave:

Los mismos fundamentos analíticos pueden aplicarse a múltiples dominios, dando origen a disciplinas especializadas adaptadas a sus datos,




Advanced Business Analytics

University of Colorado Boulder

Specialization

★★★★☆ 4.6 (4,642) | 210k students

Intermediate



Human Resources Analytics

University of California, Irvine

Course

Mar 28 - May 2, 2022

★★★★☆ 4.6 (531) | 26k students

Mixed




Supply Chain Analytics

Rutgers the State University of New Jersey

Specialization

★★★★☆ 4.6 (1,560) | 52k students

Beginner



Inventory Analytics

Rutgers the State University of New Jersey

Course

Mar 7 - Apr 11, 2022

★★★★☆ 4.5 (159) | 9k students


Beginner



Revenue and Pricing Analytics

James Lenihan, MBA, CPA
Fellow
Senior Manager, Financial Planning & Analysis
Tableau Software, Inc.

Adapt 19



Foundations of Marketing Analytics


Emory University

Specialization

★★★★☆ 4.3 (408) | 53k students

Intermediate

Rutas de formación



¿Qué aprendieron las organizaciones en estos 50 años?

Registrar
↓
Recordar
↓
Analizar
↓
Aprender
↓
Decidir
↓
Actuar

Business Analytics es la historia de cómo las organizaciones aprendieron a convertir datos en decisiones.

Si una máquina puede analizar, recomendar, decidir y ejecutar... ¿qué queda para nosotros?

Origen y Evolución de Business Analytics